Programming Assignment 1

Name: Andriani Yunita <yunita> Cole Evans < cevans 2>

1. Implementing equiprobable-random policy

```
def equiprobable_policy(state):
     if state == 0:
           return 0
     else:
           equiprobable = random.random()
           if equiprobable > 0.5:
                 return 0
           else:
                 return 1
```

We ran 10 times with 2,000 episodes for each run, and we got:

```
1 Average return: -0.331
2 Average return: -0.3105
3 Average return: -0.3355
4 Average return: -0.3285
```

5 Average return: -0.3245

6 Average return: -0.337

7 Average return: -0.363

8 Average return: -0.3565

9 Average return: -0.319 10 Average return: -0.3605

Above results showed that the average return was about -0.3.

2. Expected Sarsa

For the first check, we simply ran for 100,000 episodes with α = 0.001 and ϵ_{μ} = 1.0, and we got:

Average return at step 10000 is -0.322632263226 Average return at step 20000 is -0.331566578329 Average return at step 30000 is -0.33077769259 Average return at step 40000 is -0.330658266457 Average return at step 50000 is -0.328906578132 Average return at step 60000 is -0.32718878648 Average return at step 70000 is -0.325576079658 Average return at step 80000 is -0.328104101301 Average return at step 90000 is -0.326870298559

Average return at step 100000 is -0.328963289633

Average return: -0.32896

Now we set $\varepsilon_{\mu} = \varepsilon_{\pi} = 0.01$, and ran for 10,000,000 episodes. We observed the return every 10,000 episodes. We found that the learning progresses up to about -0.085 or better. Then, we ran the deterministic learned policy by setting ε_{μ} = 0.

(Refer to attachment p1_2.html for the full result) Learning run result:

Average return at step 10,000 is -0.0934093409341 Average return at step 1,000,000 is -0.0511720511721 Average return at step 10,000,000 is -0.0387959038796

Usable Ace:													No Usable Ace:									
S	Н	S	S	Н	S	Н	S	S	S	20		S	S	S	S	S	S	S	S	S	S	20
S	Η	Η	Η	Η	Η	Н	S	S	S	19		S	S	S	S	S	S	S	S	S	S	19
S	Η	Η	Η	Η	Η	S	S	Η	Η	18		S	S	S	S	S	S	S	S	S	S	18
Η	Η	Η	Η	Η	Η	Η	Η	Η	Η	17		S	S	S	S	S	S	S	S	S	S	17
Н	Н	Н	Н	Н	Н	Н	Н	Н	Н	16		Н	S	S	S	S	S	Н	Н	Н	Н	16
Н	Η	Η	Н	Н	Н	Н	Н	Н	Н	15		Н	Η	S	S	S	Н	Н	Н	Н	Н	15
Η	Η	Η	Η	Η	Η	Η	Η	Η	Η	14		Н	Н	Η	Η	Η	Η	Η	Н	Н	Н	14
Η	Η	Η	Η	Η	Η	Η	Η	Η	Η	13		Н	Н	Н	Н	Η	Η	Η	Н	Н	S	13
Η	Η	Η	Η	Η	Η	Η	Η	Η	Η	12		Н	Н	Н	Н	Η	Η	Η	Н	Н	Н	12
1	2	3	4	5	6	7	8	9	1()		1	2	3	4	5	6	7	8	9	10)

The result of the deterministic learned policy: Average return at step 10,000,000 is -0.0339631033963

Usable Ace: No													Us	sak	ole	e 1	Ace	∋:				
S	Η	S	S	Η	S	Η	S	S	S	20		S	S	S	S	S	S	S	S	S	S	20
S	Η	Η	Η	Η	Η	Н	S	S	S	19		S	S	S	S	S	S	S	S	S	S	19
S	Н	Н	Н	Н	Н	S	S	Н	Н	18		S	S	S	S	S	S	S	S	S	S	18
Н	Η	Η	Н	Н	Н	Н	Η	Н	Н	17		S	S	S	S	S	S	S	S	S	S	17
Н	Η	Η	Η	Η	Η	Η	Н	Η	Η	16		Η	S	S	S	S	S	Η	Η	Η	Η	16
Н	Η	Η	Η	Η	Η	Η	Н	Η	Η	15		Н	Η	S	S	S	Η	Н	Н	Н	Н	15
Н	Н	Н	Η	Η	Н	Н	Н	Η	Η	14		Н	Н	Η	Η	Η	Н	Н	Н	Н	Н	14
Н	Η	Η	Η	Η	Η	Η	Н	Η	Η	13		Н	Н	Н	Н	Η	Η	Н	Н	Н	Н	13
Н	Н	Н	Н	Н	Н	Н	Н	Н	Н	12		Н	Н	Н	Н	Н	Н	Н	Н	Н	Н	12
1	2	3	4	5	6	7	8	9	1()		1	2	3	4	5	6	7	8	9	10)

3. Better policy

We set number of episodes = 10,000,000, ϵ_{μ} = 1, ϵ_{π} = 0.01, and α = 0.01

(Refer to attachment p1_3.html for the full result)

The result of the deterministic learned policy:

Average return at step 10,000,000 is -0.0284725028473

Usable			Ac	ce:	:					1	JO	Us	sak	ole	e 7	AC6	∋:				
S	S	S	S	S	S	S	S	S	S	20	S	S	S	S	S	S	S	S	S	S	20
S	S	S	S	S	S	S	S	S	S	19	S	S	S	S	S	S	S	S	S	S	19
S	S	S	S	S	S	S	S	Н	S	18	S	S	S	S	S	S	S	S	S	S	18
Н	Η	Η	Η	Η	S	Η	Η	Н	Н	17	S	S	S	S	S	S	S	S	S	S	17
Н	Η	Η	Η	Η	Η	Η	Н	Η	Η	16											16
Н	Н	Η	Η	Η	Η	Η	Н	Η	Η	15	Н	S	Η	S	S	Η	Н	Η	Н	Н	15
Н	Н	Н	Н	Н	Н	Н	Н	Н	Н	14	Н	Н	Н	Η	Н	Н	Н	Н	Н	Н	14
Н	Н	Н	Н	Н	Н	Н	Н	Н	Н	13	Н	Н	Н	Н	Н	Н	Н	Н	Н	Н	13
Н	Н	Н	Н	Н	Н	Н	Н	Н	Η	12	Н	Н	Н	Н	Η	Н	Н	Н	Н	Н	12
1	2	3	4	5	6	7	8	9	1()	1	2	3	4	5	6	7	8	9	10)